

從繪圖核心到 AI 霸主： GPU 演進與 技術革新全解析

每一代新架構的誕生，都不是為了炫技，而是為了解決上一代面臨的致命物理極限。這是一場為期 20 年、精準踩在每一次科技痛點上的硬體演化史詩。



運算哲學的根本差異：為何 AI 的靈魂伴侶是 GPU？

任務目標：將 10,000 塊磚頭 (海量簡單矩陣運算) 搬到山頂

CPU (中央處理器)

4 位頂尖老教授 / 法拉利跑車

時速 300 公里，每次載 2 塊磚頭

擅長：單一複雜邏輯判斷

瓶頸：處理海量資料時來回奔波

GPU (圖形處理器)

4,000 位算數國小生 / 機車大軍

時速 40 公里，同時發動 1,000 台

擅長：平行運算 (Parallel Computing)

優勢：人海戰術瞬間完成大矩陣乘加

關鍵結論：AI 深度學習的本質，就是幾億次極度簡單的矩陣乘法。


奠定通用運算基礎的創世神話 Tesla 架構，2006

待解痛點：頂點（切菜）與像素（炒菜）分工死板，一方過勞一方閒置，算力嚴重浪費。

原理革新：引入「統一著色器」(Unified Shader) 與 CUDA。打破分工限制，用 C 語言直接呼叫 GPU。

效果效益：誕生通用運算 GPU (GPGPU)，正式跨足科學計算與平行運算。

Before: 傳統分工流水線



After: 統一矩陣全能廚房



走向專業與科學計算的里程碑 Fermi 架構，2010

待解痛點：GPU 運算極快但拿資料太慢，發呆等待時間極長；且缺乏除錯機制，無法應付嚴謹科學計算。

原理革新：首次內建真正的 L1 / L2 階層式快取，並加入企業級 ECC (錯誤檢查糾正) 記憶體功能。

效果效益：大幅減少資料傳輸卡脖子問題，確保運算「零出錯」，獲得超級電腦機房門票。

關鍵結論：Fermi 架構的誕生，標誌著 GPU 從遊戲玩具進化為嚴謹科學計算工具的轉折點。



極致省電與架構大瘦身


Kepler 2012 & Maxwell 2014

待解痛點：前代為衝效能採用兩倍速熱時脈，導致晶片極度耗電且發出恐怖高溫，急需改善每瓦效能。

原理革新：裁撤耗電的硬體排程主管，改用軟體事先寫好 SOP。核心打散為 4 個獨立小隊分工，並放入大幅擴充的 L2 Cache。

效果效益：將無效發呆時間與控制電路耗電降至最低，創下歷史新高每瓦效能。

Fermi：高熱時脈 + 複雜硬體排程



Kepler/Maxwell：人海戰術 + 獨立小隊 + 超級大冰箱 (L2 Cache)



待解痛點：

深度學習模型參數暴增，
傳統 PCIe 頻寬與平面
GDDR 面臨物理極限，
GPU 算得快卻常常被餓死。

原理革新：

發明 NVLink 取代 PCIe
繞過 CPU 架設專屬高速
公路。引入 HBM2，透
過 3D 堆疊與矽穿孔蓋出
立體記憶體大樓。


效果效益：

徹底解決單卡內部資料
飢荒與多卡溝通障礙，
史上第一張為 AI 巨型模
型打造的怪獸卡誕生。


AI 狂飆期的開端與拓荒者

Pascal 架構, 2016

平面平房：傳統 GDDR + PCIe 十字路口



3D 摩天大樓：HBM2 (4096-bit) + NVLink 專屬高鐵



降維打擊的矩陣革命


Volta 架構，2017

待解痛點：面對 AI 幾億次的「大矩陣乘加運算」，傳統 CUDA 核心需一個一個數字算，硬體設計遇到天花板。


原理革新：硬生生切出專屬硬體「Tensor Core」。能在單一週期內，瞬間把整塊 4x4 矩陣同時相乘並加總 (MAC)。

效果效益：深度學習訓練速度飆升 12 倍！沒有這個專屬印章，就不可能有今天的巨型語言模型。

傳統 CUDA：收銀員逐一掃描條碼 (需多個時脈)



Tensor Core：4x4 方型大印章，一槌定音 (1 個時脈)



捨棄無效精準，換取極速吞吐 Turing 架構，2018

待解痛點：AI 終端推論不需要極端精準的浮點數，FP16 太浪費算力。遊戲界則渴望真實的物理光線模擬。

原理革新：Tensor Core 強勢支援極低精度 INT8 / INT4 整數運算。並加入專職光線追蹤的 RT Core。

效果效益：透過量化壓縮數字體積，單一時脈吞下 4 到 8 倍資料量。推論速度暴增且大幅節省 VRAM。

1 個時脈週期 (Clock) 的吞吐量極限

FP32 高精度：
2 個 (160kg 胖子)

INT4 極低精度：
16 個 (20kg 小孩)

RT Core

全自動剝蝦機，解放核心算力

極致共享的影分身之術

Ampere 架構，2020

待解痛點：頂級 GPU 極度昂貴，傳統軟體虛擬化就像「室友共用大廚房」，極易互相卡頓干擾，資源利用率低。

原理革新：引入 MIG（多執行個體 GPU）硬體分割技術。在物理層面直接把晶片、快取與頻寬精準切開。

效果效益：一張卡安全切分為 7 間互不干擾的獨立小套房，極大化雲端資料中心的投資報酬率。



為 LLM 量身打造的自動變速箱 Hopper 架構，2022

待解痛點：巨型語言模型規模飛速膨脹，導致嚴重的記憶體卡脖子窘境。需要聰明判斷何時精準、何時粗略。

原理革新：首創「Transformer 引擎」，原生支援 FP8。透過 Scaling Factor 動態統計，在每層運算中自動變速切換。

效果效益：完全不損失模型準確度下，節省 HBM3 頻寬。吞吐量暴增 6 倍，大幅縮短 ChatGPT 訓練時間。



突破物理極限的超級大腦

Blackwell 架構，2024

待解痛點：單一矽晶片面積已達光罩極限 (858 mm²)，無法再塞入更多電晶體以滿足龐大算力需求。

原理革新：首次將兩顆裸晶無縫縫合為一顆超級 GPU。並升級支援 FP4，主推 GB200 NVL72 一體化機櫃。

效果效益：透過 1800 GB/s 的 NVLink 打通全身。不再賣單張卡，而是把整個 72 顆 GPU 的機櫃化為單一超級大腦。

Step 2:
機櫃級超級大腦
(72顆 GPU 融合)


Step 1: 雙晶片無縫合併
(突破光罩極限)

專為 AI 代理打造的究極引擎 Rubin 架構，2026

待解痛點：代理型 AI (Agentic AI) 需要極長上下文記憶與複雜自主邏輯分支，傳統 CPU 成為調度瓶頸，使 GPU 閒置。

原理革新：搭載全自研 Olympus 核心的 Vera CPU。HBM4 底層改由台積電高階「邏輯製程」代工，拓寬至 2048-bit。

效果效益：完美消化海量上下文切換，提供 50 Petaflops 推論算力，確保這座 AI 工廠永不停機。



打破距離極限的光學擴展

Rubin Ultra，預計 2027

待解痛點：機櫃間的傳統銅線傳輸已面臨耗電、發熱與物理距離極限，訊號衰減嚴重。

原理革新：捨棄銅線，採用 CPO（共同封裝光學）。將矽光子元件封裝於 GPU 旁，光電轉換距離縮至數公釐。

效果效益：提升 5 倍能源效率。透過光學擴展（Kyber 機櫃）串聯高達 576 顆 GPU，化身單一超級虛擬大腦。



難以跨越的護城河：極端協同計 (Extreme Co-Design)

核心洞察：摩爾定律在單顆晶片上已失效。
NVIDIA 的解法不再是「做更強的單一顆 GPU」
，而是從終點終點往回設計的全系統一體化。

原理革新：摩爾定律，單顆晶片的功能與
光鎖，外解法邊界一體化設計，而是從終
點回設計的全系統一體化。


最終結論：未來的算力單位不再是 GPU，
而是「AI 工廠」。打破部門邊界的一體化設
計，才是 AI 算力呈指數級狂飆的真正秘密。

CUDA 與
Transformer
演算法

NVLink
光學網路與
800V 液冷機櫃


CoWoS-L 封裝
與 CPO 矽光子

台積電 3nm
矽晶片與
HBM4



GPU 世代演進總表：

從繪圖晶片到 AI 大腦的進化軌跡



結語：現在的 AI 奇蹟，皆建立在過去 20 年每一次精準踩中物理痛點的硬體革命之上。